

AL+SSL联合策略技术报告

1. 策略概述

本报告详细描述主动学习（AL）与半监督学习（SSL）联合策略的技术实现。该策略旨在低标注预算（ $n_{\text{initial}}=100$, $n_{\text{query}}=100$, $n_{\text{rounds}}=10$ ）下，针对CIFAR-10长尾分布图像分类任务，通过AL选择最有价值的样本标注，同时利用SSL（FlexMatch）从大量未标注数据中学习，实现标注效率的最大化。

2. 核心技术组件

2.1 FlexMatch动态阈值机制

设计思想：传统FixMatch使用统一置信度阈值（ $\tau=0.95$ ），在长尾分布下尾类样本难以达到该阈值，导致伪标签严重偏向头类。FlexMatch通过EMA（指数移动平均）跟踪每个类别的学习状态，动态调整各类别的置信度阈值。

实现细节：

```

class FlexMatchTracker:
    def __init__(self, n_classes, threshold=0.95, ema_momentum=0.9, min_threshold=0.70):
        self.classwise_acc = torch.zeros(n_classes) # EMA学习状态
        self.current_thresholds = np.full(n_classes, threshold)

    def update_per_batch(self, weak_probs):
        # 1. 计算每个样本是否超过基础阈值
        max_probs, pseudo_labels = weak_probs.max(dim=1)
        batch_exceeds = (max_probs >= self.base_threshold).float()

        # 2. 按类别EMA更新学习状态
        for c in range(self.n_classes):
            mask = pseudo_labels == c
            if mask.sum() > 0:
                class_effect = batch_exceeds[mask].mean()
                self.classwise_acc[c] = (
                    self.ema_momentum * self.classwise_acc[c]
                    + (1 - self.ema_momentum) * class_effect
                )

        # 3. 根据学习状态重新计算阈值
        max_effect = self.classwise_acc.max()
        for c in range(self.n_classes):
            beta = self.classwise_acc[c] / max_effect
            self.current_thresholds[c] = max(self.min_threshold, self.base_threshold * beta)

```

阈值调整逻辑：

- 头类：学习状态好 → beta接近1 → 阈值接近0.95（保持高质量）
- 尾类：学习状态差 → beta小 → 阈值降至0.70（降低门槛，增加伪标签数量）

2.2 FixMatch一致性正则化

核心流程：

1. 对未标注样本施加强增强（随机裁剪+水平翻转），生成预测概率
2. 若最大概率超过类别自适应阈值 τ_c ，生成伪标签
3. 对同一样本施加强增强（RandAugment），计算与伪标签的一致性损失

数据增强策略：

增强类型	方法	参数
弱增强	RandomCrop + HorizontalFlip	padding=4
强增强	RandAugment	num_ops=2, magnitude=10

伪标签生成：

```
# 弱增强预测
weak_probs = model(weak_augmented_images)
max_probs, pseudo_labels = weak_probs.max(dim=1)

# 动态阈值筛选
thresholds = flexmatch_tracker.get_thresholds()
mask = max_probs >= thresholds[pseudo_labels]

# 强增强一致性损失
strong_probs = model(strong_augmented_images)
loss_u = CrossEntropy(strong_probs[mask], pseudo_labels[mask])
```

2.3 AL查询策略

本系统支持6种AL查询策略，覆盖不确定性采样、多样性采样和混合方法：

策略	类型	核心思想
Random	基线	随机选择，无偏好
Entropy	不确定性	选择预测熵最大的样本
Margin	不确定性	选择最大与次大概率差最小的样本
CoreSet	多样性	k-center贪婪算法，最大化特征空间覆盖
Badge	混合	梯度嵌入空间中的不确定性+多样性
QBC	混合	5个异构CNN委员会投票熵

Class-Aware Entropy（尾类感知策略）：

```
score(x) = Entropy_norm(x) + λ · Penalty_norm(ŷ(x))
# 其中:
# Entropy_norm(x) = H(p(x)) / log(C), 归一化到[0,1]
# Penalty(c) = 1 / log(n_c + 2), n_c为类别c的已标注样本数
# λ = 0.5, 平衡不确定性与类别惩罚
```

Gap-Aware Entropy（分布差距感知策略）：

```
score(x) = Entropy_norm(x) + λ · Gap_norm(x)
# 其中:
# deficit(c) = max(1/C - f_c, 0), f_c为类别c的已标注频率
# Gap(x) = Σ_c p(x,c) · deficit(c)
# 使用概率加权而非硬预测，避免低预算下预测不可靠
```

2.4 AL+SSL联合训练流程

每轮训练流程：

第r轮 AL+SSL联合训练
1. SSL阶段： - 对未标注数据施加强增强+弱增强 - FlexMatch动态阈值筛选伪标签 - 计算一致性损失 L_u
2. AL阶段： - 使用当前模型对未标注池预测 - 应用查询策略（Entropy/Margin/Badge等） - 选择n_query=100个样本请求标注
3. 模型更新： - L_total = L_labeled + λ_u · L_u - 使用标注数据+伪标签数据联合训练

3. 实验配置

3.1 统一配置

参数	值	说明
数据集	CIFAR-10	10类图像分类
模型	SimpleCNN	3层卷积+FC，参数量约1.1M
n_initial	100	初始标注量
n_query	100	每轮查询量
n_rounds	10	AL轮数
不平衡比率	$\rho \in \{1, 10, 50, 100\}$	从均衡到极端长尾
种子	42,123,456,789,1024	5种子统计
评估指标	Macro-F1	对尾类敏感

3.2 SSL配置

参数	值
SSL方法	FlexMatch
基础阈值	0.95
最低阈值	0.70
EMA动量	0.9
强增强	RandAugment(num_ops=2, magnitude=10)
λ_u (SSL损失权重)	1.0

4. 实验结果

4.1 AL+SSL联合策略在CIFAR-10上的表现

策略	$\rho=1$	$\rho=10$	$\rho=50$	$\rho=100$
Random	0.2526±0.011	0.1704±0.026	0.0803±0.018	0.0871±0.021
Entropy	0.2341±0.021	0.1697±0.022	0.1039±0.016	0.1017±0.032
Margin	0.2277±0.027	0.1669±0.014	0.0914±0.024	0.0804±0.018
Badge	-	-	-	-
CoreSet	-	-	-	-
QBC	-	-	-	-

注：Badge/CoreSet/QBC实验数据待补充（正在运行中）

4.2 关键发现

- 平衡数据 ($\rho=1$) 下Random最优：**Random (0.2526) 优于Entropy (0.2341)，说明在无类别偏差时，不确定性采样反而引入噪声。
- 长尾数据 ($\rho\geq 50$) 下Entropy最优：** $\rho=50$ 时Entropy比Random提升+29.4%； $\rho=100$ 时提升+16.8%。不确定性采样在长尾分布下能更有效地识别有价值的样本。
- 全监督性能随 ρ 急剧下降：**从 $\rho=1$ 的0.7751降至 $\rho=100$ 的0.3917，验证长尾分布的严重挑战。
- SSL的双重作用：**
 - 正面：为头类生成大量伪标签，扩大有效训练集
 - 负面：在长尾分布下伪标签偏向头类，可能加剧类别不平衡

5. 技术创新点

5.1 FlexMatch动态阈值的长尾适应性

传统FixMatch使用统一阈值 $\tau=0.95$ ，对尾类过于严格。FlexMatch通过EMA跟踪各类别学习状态，自动降低尾类阈值：

- 头类：**学习充分 → 阈值保持0.95 → 伪标签质量高
- 尾类：**学习不足 → 阈值降至0.70 → 伪标签数量增加

这种自适应机制使得SSL在长尾分布下仍能为尾类生成有效伪标签。

5.2 AL与SSL的协同效应

AL选择有价值的样本进行标注，SSL利用大量未标注数据扩充训练集。两者形成正反馈：

AL选择尾类样本 → 模型尾类能力提升 → SSL生成更准确的尾类伪标签
→ 模型进一步提升 → AL自动调整查询策略

5.3 多策略覆盖

系统支持6种AL策略，从简单随机到复杂梯度嵌入方法，覆盖不同场景需求：

- **不确定性采样**（Entropy/Margin）：适合模型置信度可靠的场景
- **多样性采样**（CoreSet）：适合特征空间复杂的场景
- **混合方法**（Badge/QBC）：平衡不确定性与多样性

6. 与现有方法的对比

方法	思路	低预算效果	长尾适应性
LDAM+DRW	修改损失函数	✗ 差	✗ 低预算下失效
标准AL	选择有价值的样本	✓ 一般	✗ 未考虑类别分布
标准SSL	利用未标注数据	✓ 一般	✗ 伪标签偏向头类
AL+SSL联合	AL选择+SSL扩充	✓ 最优	✓ FlexMatch自适应

7. 局限性与未来工作

1. **计算成本**：Badge/CoreSet等策略需要计算梯度嵌入或成对距离，计算量较大
2. **伪标签质量**：即使使用FlexMatch，尾类伪标签的准确性仍低于头类
3. **策略选择**：不同p值下最优策略不同，缺乏自动策略选择机制

未来方向：

- 引入对比学习增强特征表示
- 设计自适应策略选择机制
- 探索更多图像数据集（FashionMNIST, CIFAR-100）上的泛化性

8. 代码结构

```
src/
├── ssl_v7_utils.py          # FlexMatch + FixMatch实现
│   ├── FlexMatchTracker    # 动态阈值跟踪器
│   ├── UnlabeledDataset    # 双增强数据集
│   └── make_longtail_indices # 长尾分布构造
├── deep_query_utils.py      # AL查询策略
│   ├── select_random       # 随机选择
│   ├── select_uncertainty   # 熵查询
│   ├── select_class_aware_entropy # 尾类感知
│   └── select_gap_aware_entropy # 分布差距感知
└── models.py               # SimpleCNN模型定义

experiments/
├── v8_controlled_fast_al_ssl.py # 主实验框架
├── run_al_ssl_100.py            # AL+SSL实验入口
├── run_std_al_100.py           # 标准AL实验
├── run_tail_aware_100.py       # 尾类感知实验
└── run_ldam_baseline.py        # LDAM基线实验
```