

演讲稿（12分钟版）

第1页：封面

大家好，我汇报的题目是《低标注预算下面向不平衡图像分类的主动学习与半监督学习联合策略研究》。

这个研究要解决的问题其实很现实——我们都知道深度学习需要大量标注数据，但在医疗影像、工业检测这些场景里，找专家标注一张图像可能要花好几个小时。更麻烦的是，真实世界的数据分布往往是不平衡的，常见病的图像很多，罕见病的图像很少。所以我想研究的就是：在这种"标注少+数据不平衡"的双重约束下，怎么尽可能少地标注，训练出尽可能好的模型。

第2页：目录

今天的汇报我分八个部分来讲。先说背景和问题，然后介绍实验怎么做，接着展示标准方法的结果——你会发现它们在不平衡数据上确实不太行。然后我会介绍我们提出的两种改进策略，通过消融实验分析哪个贡献更大，再讨论策略的失效边界，最后和其他方法对比，做个总结。

第3页：核心矛盾

这张图展示的就是核心矛盾。左边是标注成本高——专家标注一张CT可能要几个小时；右边是未标注数据多——互联网每天产生海量图像，获取成本几乎为零。

所以我们提出了三个研究问题：第一，标准的主动学习策略在不平衡数据上是不是真的失效了？第二，如果失效了，怎么设计能感知少数类的策略？第三，主动学习和半监督学习怎么配合？

研究的主线是这样的：先在平衡数据上看AL和Random差距大不大，然后逐步增加不平衡程度，观察差距怎么变化，最后提出改进方案。

第4页：标准AL结果

先看标准方法的结果。我们测了6种主动学习策略，覆盖了三大范式：不确定性采样（Entropy、Margin）、多样性采样（CoreSet）、以及混合方法（BADGE、QBC）。

从表中可以看到， $p=1$ 就是平衡数据，各策略差异只有5%左右，QBC最好。随着 p 增大，策略开始分化，但差距仍然有限。到 $p=100$ 极端不平衡时，Margin最好但也就0.26。

这说明一个关键问题：标准AL策略在长尾分布下效果有限，策略之间的差异并不大。那怎么办呢？这就引出了我们的创新。

第5页：创新策略

我们提出了两种尾类感知的AL策略。

第一种叫Class-Aware Entropy。核心思想很简单：在原来的Entropy基础上，对预测为少数类的样本加一个奖励。公式里 $\text{Penalty}(c) = 1/\log(n_c+2)$ ， n_c 越小惩罚越大，所以少数类的样本得分更高，更容易被选中。

第二种叫Gap-Aware Entropy。它不看预测类别，而是计算每个样本对填补分布差距的期望贡献。用概率加权而不是硬预测，对噪声更鲁棒。

另外我们还做了联合分布感知——把模型预测的伪标签也纳入类分布计算，让AL知道SSL已经覆盖了哪些类。

结果呢？ $p=50$ 时Class-Aware比标准Entropy提升了21%，效果还是很明显的。另外我们对比了FixMatch和FlexMatch，发现两者表现相近（ $p=10$ 时0.3567 vs 0.3565），说明动态阈值在中等不平衡下并没有明显优势。

第6页：渐进式联合分布

但是联合分布有个问题：全程开启的话， $p=100$ 下伪标签噪声太大，模型早期不可靠。

所以我们提出了渐进式调度——前期只用人工标注的类分布，等模型学得差不多了，后期再引入伪标签。从表中可以看到， $p=100$ 时渐进r5比纯AL提升了9.1%。

规律很清楚： ρ 越大，需要越晚切换。这是因为极端不平衡下，模型需要更长时间才能对少数类产生可靠的预测。

第7页：消融实验

接下来是消融实验，回答一个关键问题：AL创新和SSL创新，到底哪个贡献更大？

从表中可以看到，AL创新+基础SSL提升了16.8%，但SSL创新单独使用反而下降了2.5%。AL创新是主要贡献来源。

为什么AL创新有效？因为我们发现Class-Aware策略不仅帮助了尾类，也帮助了被忽视的多数类—— $\rho=50$ 时Head类F1从0.2169提升到0.2729（+25.8%），Middle类从0.1815提升到0.2454（+35.2%）。

为什么SSL创新失效？因为deficit阈值降低了尾类伪标签的门槛，但低预算下模型对尾类预测不准确，伪标签准确率从71%降到了57%，引入了大量噪声。

所以核心教训是：在低标注预算下，策略优化应该聚焦在AL侧，而不是SSL侧。

第8页：渐进式SSL

针对SSL创新失效的问题，我们提出了渐进式调度：前期用Base SSL保证伪标签质量，后期再切换到创新SSL引入类别感知。

从表中可以看到， $\rho=100$ 时渐进式比Base SSL提升了20.5%。这说明"先保质量，再引入创新"的思路是有效的。

第9页：失效分析

当然，创新策略不是万能的。我们分析了三个失效场景。

$\rho=1$ 平衡数据时，惩罚项对各类别都差不多，反而引入噪声，创新策略比标准策略低3-10%。

$\rho=100$ 极端长尾时，尾类样本太少，类分布估计不稳定，但渐进式联合分布仍有提升。

CIFAR-100上每类只有约10个样本，属于"极度稀疏样本域"，任何策略都难以有效。

所以创新策略的适用条件是：类间分布差异足够大、类内样本足够多、类别数不能太多。

第10页：LDAM/CB基线

我们还和传统的损失函数方法做了对比。

LDAM在全量数据上比CE提升3.7%-5.6%，但问题是它需要全量标注数据，不适用于我们这种低标注预算的场景。CB Loss和Focal Loss是另外两种损失函数层面的改进。

我们的方法和这些方法是两条独立的改进路径——我们优化的是"选哪些样本标注"，他们优化的是"怎么用已有的标注"。我们的方法仅用不到10%的标注就能达到合理的性能。

第11页：ResNet-18验证

为验证策略在更深层网络上是否有效，我们在ResNet-18上重复了实验。

ResNet-18比SimpleCNN提升了83%，这很正常——深层网络特征提取能力更强。关键是，我们的创新策略在ResNet-18上也有效，Adaptive Gap达到了0.4807，优于Entropy的0.4737。这说明结论是跨模型成立的。

第12页：CIFAR-100交叉验证

我们还在CIFAR-100上做了交叉验证。100类加1000个标注，每类只有约10个样本，F1普遍很低。

创新策略在这里优势不明显，但这不是策略的问题——每类只有10个样本，任何方法都很难学到有效的特征。这说明我们的策略有明确的适用边界。

第13页：Per-Class F1分析

我们还做了逐类分析。以 $p=50$ 为例，把10类分成Head (0-2)、Middle (3-6)、Tail (7-9) 三组。

Class-Aware策略相比Entropy：Head类提升+25.8%，Middle类提升+35.2%，Tail类提升+21.8%。可以看到各类别组都有提升，Middle类提升最大。

联合分布策略（CA_ssl）进一步提升了Middle和Tail：Middle类从0.1815提升到0.2764（+52.2%），Tail类从0.3839提升到0.4816（+25.4%）。

但 $p=100$ 时，创新策略反而损害了Head类。这是因为尾类样本太少，惩罚项的噪声太大，反而误导了模型。

第14页：TML对比

最后我们在LR和RF上也测了AL策略。结果显示，TML模型上策略分化不到5%，而DL模型上超过10%。这说明AL策略的价值依赖于模型的特征提取能力，进一步验证了深度学习在图像任务上的不可替代性。

第15页：总结

总结一下。核心贡献有三点：一是尾类感知AL策略， $p=50$ 时提升21%；二是联合分布感知，让AL知道SSL已经覆盖了哪些类；三是渐进式调度，解决了极端长尾下联合分布失效的问题。

关键发现是：标准AL在长尾下效果有限，AL创新是主要贡献来源，SSL创新在低标注预算下反而有害，策略有效性有明确边界。

未来可以探索预训练特征加AL策略、特征空间分布估计等方向。

谢谢大家，欢迎提问。